

査読結果通知書・査読報告書（Peer Review Report）

審査対象論文	得点の高い国ほど数学の男女差は小さいのか：PISA 2025の90の国・地域で確かめる
論文審査区分	生成AI論文（学術査読論文 / 刷り4頁以内）
査読判定結果	【条件付採録（Major Revision）】
査読実施方式	生成AI（LLM / 模擬査読シミュレータ）による自動審査（学生教育・推敲支援）

1. 審査評価マトリクス（Evaluation Matrix）

審査評価項目	評価	評価所見および審査基準
独創性・新規性	C	PISAの国別男女差と平均得点水準の関連は既往研究（Guiso et al., 2008等）で繰り返し扱われた古典的テーマであり、概念的新規性は乏しい。PISA 2025という新しい公表値を用いた点、および7か国選択による相関符号反転を無作為抽出（5,000回）で評価した点には小さな貢献がある。ただし、後者は『選び方で結論が変わる』という方法的警告として整理すべきで、知見としての独創性は限定的である。
有用性・教育的貢献	C	日本が高得点国でありながら男子優位が標準誤差を超える位置にあることを示す記述は、教育政策論議の基礎資料として一定の有用性がある。一方、効果量が算出されておらず、得点差16.3点の実質的大きさ（標準偏差比でどの程度か）が読者に伝わらない。また、全体としての記述にとどまり、教育実践・政策への含意は意図的に抑制されている。この抑制は妥当だが、有用性の評価を下げる。
信頼性・統計的妥当性	C	【良い点】比率擬似相関・部分-全体交絡の問題は基本的に回避されている。平均得点（男女計）と男女得点差（男子-女子）の関連では、男女計平均は男女平均の加重平均であるため、差と数学的に完全に独立ではないが、致命的な恒等式回帰ではない。除外・重み付け・ブートストラップ・無作為7か国抽出など頑健性確認は丁寧である。【問題点】(1)男女計平均 $M=(w_m \cdot M_m + w_f \cdot M_f)$ と差 $D=M_m - M_f$ の関連には、男女の標本比率・分散構造に由来する機械的な連動の余地があり、これを明示的に検討していない。(2)平均得点と男女差の双方に測定誤差（標準誤差）があるが、男女差の標準誤差が大きい国ほど見かけの差が極端になるため、分散の異質性（heteroscedasticity）と減衰・拡大の問題を扱う必要がある。重み付け分析は行われているが、変量効果メタ回帰の枠組みで測定誤差を正式にモデル化していない。(3) $r=.31$ のBF10=5.91は『中程度の証拠』にとどまるが、本文は『平均得点が高いほど男女差が小さいという予想は支持されなかった』と結論する一方、abstractでは『弱い正の相関』を積極的に報告しており、トーンが統一である。さらに、30ずつの3群（6.7, 3.8, 13.6点）で非線形が示唆されるにもかかわらず、線形相関を主要指標としている点は解釈上の緊張を孕む。(4)上位30か国で $r=.10$ （ $p=.59$ ）と関連が消失する結果は、全体の $r=.31$ が主に低～中位群と最上位群の対比（特定の地域・体制の群による構造）に依存する可能性を示唆するが、分析が不十分。(5)6か国の標本抽出基準注意（*）を『除外しても $r=.29$ 』と頑健性確認するのは良いが、限界(4)で『考慮していない』と書くのは自己矛盾に近く、整理が必要。(6)多重比較補正で判定数が大きく変わる（55→44/60）ことを報告しながら、本文・abstractの主要数値は未補正值で提示されており、読者に誤解を与える。【総合】致命的ではないが、測定誤差・機械的連動・非線形性の取り扱いに不備があり、C判定とする。
論理的一貫性・構成	B	RQ1・RQ2・結果・考察の対応は明瞭で、『予想に反して正の相関』『7か国選択では逆向き』『国・地域単位の関連であり個人の因果ではない』という結論はデータの範囲内に収まり、強弁は少ない。生態学的誤謬の回避意識も一貫している。一方、(a)Guiso et al.の男女平等指標との関連に触れつつ『平均得点は男女平等の代わりにならない』と述べるが、本稿データに平等指標がないため論拠が弱い、(b)ジェンダー類似性仮説（Hyde et al.）との接続が『効果量がないので比較できない』で終わっており、理論枠組みとの対話が実質的に放棄されている、(c)ステレオタイプ脅威への言及が単なる列挙にとどまる、という点で理論的深化が不足している。
表現・体裁・引用規範	C	参考文献が8本と極端に少なく、ショートレートとしても、国際比較における男女差研究（Stoet & Geary 2018のGender-Equality Paradox、Else-Quest et al. 2010の後続研究、Hyde & Mertz 2009、OECDの技術報告書等）を網羅できていない。日本語として概ね明晰だが、『偶然的範囲を超える』という表現は統計的有意性の誤解を招きやすく、『標準誤差を考慮して差が推定されたと言える』などへの修正が望ましい。小数点以下の桁・図表の有無など体裁面の記述も不足している（図表の言及がない）。

2. 総合講評（Overall Critique）

本稿は、PISA 2025の公表値90か国・地域を用い、数学の男女得点差の分布と平均得点との関連を記述した堅実な短報である。比率擬似相関のような致命的欠陥は回避され、頑健性確認（除外・重み付け・ブートストラップ・Holm/BH補正・無作為7か国抽出）も丁寧で、生態学的誤謬への自覚も明示されている点は評価できる。他方、(1)男女計平均と男女差の関連における測定誤差・機械的連動の扱い、(2)非線形性（群別平均6.7/3.8/13.6）や上位群での関連消失（ $r=.10$ ）にもかかわらず線形 $r=.31$ を主要指標とする点、(3)Hyde・Guiso・Spencerという枠組みとの実質的対話の欠如（効果量未算出）、(4)参考文献の過少、(5)標本抽出基準に注意が付く6か国の扱いの整理不足、が残る。致命的な方法論的破綻はなく、データと主張の整合性も概ね保たれているため不採録には当たらないが、統計モデルの精緻化と理論的接続の強化を要する大幅修正（Major Revision）と判定する。

3. 主要修正要求事項（Major Revisions：採録に向けた必須対応事項）

以下の各項目は、学術論文としての信頼性および科学的妥当性を担保するために不可欠な修正要求です。再提出時には、修正箇所および各指摘への対応理由を明記した「修正対照表（Rebuttal Letter）」を必ず添付してください。

【要求 1】【測定誤差と機械的連動の統制】男女計平均（M）と男女差（ $D=Mm-Mf$ ）の間には、男女の標本構成比や分散構造に由来する機械的な連動の可能性がある。男女差の標準誤差を明示的にモデル化した変量効果メタ回帰（または errors-in-variables回帰）を実施し、男女平均の別々の水準（男子平均・女子平均それぞれと差との関連）も併せて示すこと。『男子・女子の平均がそれぞれどう動くか』を分解して報告しなければ、平均得点と差の関連の実体が不明確である。

【要求 2】【非線形性・群構造の解釈の整合化】三分位別平均（6.7/3.8/13.6点）がU字型を示し、上位30か国内では $r=.10$ と関連が消える一方、全体で $r=.31$ となる点を、線形相関の限界として正面から扱うこと。スプライン・LOESS・区分回帰等で関数形を検討し、全体の正の相関が『低～中位群と最上位群の差』に由来するのか、特定の地域群（東アジア・中東・欧州等）の構造効果なのかを検証すること。散布図（国名ラベル付き）と残差分析を必須とする。

【要求 3】【理論枠組みとの実質的接続】効果量（標準偏差で割った差）を算出できない点を理由に、Hyde et al.（ジェンダー類似性仮説）との比較を放棄しているが、OECDは国ごとの標準偏差や国内ばらつき（PISA 2025の技術報告書・データベース）を公表している。それらを用いてCohen's d等を算出し、『小さな差』の基準（例： $|d| < 0.10 \sim 0.20$ ）に照らして実質の大きさを評価すること。また、Guisoらの男女平等指標（GGGI、GII等）やStoet & Gearyの『ジェンダー平等パラドックス』等の外部指標を付加した追加分析を行い、少なくとも平均得点と男女平等の関連（共線性）を確認すること。ステレオタイプ脅威は測定変数がないため検証不可と明記し、考察での過剰な示唆を避けること。

【要求 4】【多重比較補正值の主結果への反映】abstractと本文の主結果が未補正の判定（男子55・女子7）で提示され、補正後（Holm: 44、BH: 60）が付随的に扱われている。主結果としてFDR補正後の判定数を併記し、『偶然の範囲を超える』という表現を『統計的に差が推定される』等に改め、個別国の判定は目安であることを図表上でも明示すること。

4. 軽微な修正事項（Minor Revisions：表現・体裁等の改善点）

- 参考文献が8本と著しく少ない。国際比較における男女差・ジェンダー平等パラドックス・PISA方法論（標本設計・可能値の扱い・標準誤差の算出）に関する先行研究を追加し、PISA 2025の技術文書も引用すること。
- 標本抽出基準の注意がある6か国（カナダ・アメリカ等）について、限界(4)で『考慮していない』と書きつつ頑健性分析で除外した結果（ $r=.29$ ）を報告しているのは記述が不整合である。該当する国名を明示し、限界の記述を実際の内容に合わせて修正すること。ウズベキスタンを除外した理由（公表値欠損）の扱い、欠損が結果に与え得る偏りについても一言触れること。

5. 著者への試問・照会事項（Questions to Authors）

- 男女計平均は男子平均・女子平均の加重平均であり、男女差は両者の差である。男子平均と女子平均それぞれと男女計平均との関連を分解した場合、 $r=.31$ は『男子平均が高い国ほど差が大きい』『女子平均の上昇が相対的に小さい』のいずれに由来するのか。この分解を示していただけないか。
- 上位30か国で $r=.10$ 、全体で $r=.31$ 、三分位群平均がU字型を示すことから、全体の正の相関はどの国群（地域・制度・経済水準）の構造に依存していると考えるか。東アジア圏と欧米圏で別々に分析した場合の結果はどうか。
- OECDが公表する国別標準偏差や国内分布を用いて効果量を算出し、Hyde et al.（2008）が基準とした $|d| \approx 0.0 \sim 0.1$ 程度の『ほぼゼロ～小さい』差との比較を行うことは可能か。可能でない場合、その具体的理由は何か。

6. 研究倫理および生成AI利用開示に関する審査所見

原稿情報には付記（生成AI利用開示）の具体的記述が含まれておらず、category欄に『生成AI論文』とのみ示されている。本査読では、どの工程（データ取り込み、数値計算、モンテカルロ抽出、文章生成、図表作成）で生成AIが使用されたか、人間の著者による検証範囲、数値の再現可能性（コード・データの公開）が不明である。ブートストラップ・5,000回の無作為抽出・JZSベイズファクター・Holm/BH補正等の計算過程を第三者が再現できるよう、コードと元データ（OECD表の取り込み値）を補遺で公開し、生成AIの利用範囲と人間による検証手続きを明示することを強く求める。開示の透明性は現状『不十分（評価保留）』と判断する。

7. 本査読報告書の作成に関する開示（生成AIによる査読シミュレーション）

【付記：査読レポートの自動生成に関する透明性開示】
本査読報告書は、学術論文執筆を学ぶ学生や若手研究者への教育支援（批判的推敲プロセスの模擬体験）を目的として、大規模言語モデル・生成AI（Anthropic Claude / Google Gemini）を活用して自動生成された模擬査読レポートです。教育統計学・教育工学の厳格な学術基準（マクロ集計データの制約、生態学的誤謬の回避、交絡因子の統制、論理的整合性等）に準拠した指摘を行っていますが、実際の論文修正や教育現場への適用にあたっては、指導教員等の専門的助言とともに批判的に吟味してください。

【査読担当委員 審査所見結び】

本論文は公的オープンデータを適切にハンドリングし、教育工学的示唆を導出しようとする真摯な試みとして高く評価できます。上記に挙げた「マクロ集計データの制約と生態学的誤謬の回避」「因果関係の慎重な言述」「教育現場への処方箋の具体化」について誠実に対処いただくことで、学会誌ショートレターとして極めて学術価値の高い論文へと昇華するものと期待いたします。