

査読結果通知書・査読報告書（Peer Review Report）

審査対象論文	算数・数学を「とても好き」と答える子の割合と国・地域の平均得点：TIMSS 2023の公表値による国際比較
論文審査区分	生成AI論文（学術査読論文 / 刷上り4頁以内）
査読判定結果	【 条件付採録（Major Revision） 】
査読実施方式	生成AI（LLM / 模擬査読シミュレータ）による自動審査（学生教育・推敲支援）

1. 審査評価マトリクス (Evaluation Matrix)

審査評価項目	評価	評価所見および審査基準
独創性・新規性	C	国別集計における「好き・自信・価値」と得点の負の関連は、TIMSS/PISAを用いた先行研究（Shen & Tam, 2008等）で繰り返し報告されてきた既知の現象である。本稿の新規性は、TIMSS 2023の最新値への更新、小4と中2の併記、層間得点差の整理、日本の位置づけに限られる。「好き」と「価値」の $r=.93$ の連動を共通の回答様式の反映として疑う点には一定の着眼があるが、検証されておらず、貢献は記述的更新の域にとどまる。
有用性・教育的貢献	B	国際比較で「好き」の割合を学力の指標や目標として直接読むことへの警告として、教育現場・政策担当者に有用な示唆がある。また、国内の層間得点差（中2で平均109点）と国間関連の乖離を並置した点は教育的に有益である。ただし、日本への教育的含意（「自信を育てる手立て」）は本分析から導けず、考察末尾の記述が裏付けを欠く。
信頼性・統計的妥当性	C	【良い点】比率×全体量型の部分-全体恒等式回帰や、データセットに存在しない指標の分析といった致命的欠陥は見当たらない。報告指標はデータ収録項目の範囲内で、RQと結果の対応も概ね取れている。 r 、95%CI、Spearman ρ 、BF10、外れ値除外の併記は丁寧で、探索的ペア選択でないことの明記や、小4・中2を混ぜない設計も適切である。小4「好き」と「得点差」の $r=.27$ ($p=.040$, $BF10=0.84$) を「証拠不十分」とした慎重な解釈も評価できる。【問題点】(1) 単純相関のみで、交絡（1人当たりGDP、SES、教育制度、学習時間、授業での試験圧力、受験競争等）が未統制。特に、低得点国に「好き」割合が高い国が集中する構造は、経済水準・調査参加国の構成の影響を強く疑わせる。(2) 国・地域を等ウェイトで扱っており、人口・標本規模・測定精度（公表値の標準誤差）の差が考慮されていない。(3) 多重比較の扱いが不明確（報告する相関の数に対する調整、 p 値の解釈基準）。(4) 「平均得点の低い3か国・地域を除いても関連が変わらない」とあるが、高「好き」側の端点（ウズベキスタン80%等）の影響やクラスター（中東・中央アジア・欧州等）の影響は未検討である。(5) 国内の「自信あり層と自信なし層の得点差」が自信の因果効果を示さない点は本文で適切に述べられているが、層間差を国間で比較する分析（RQ）がやや弱く、結果記述が「好き×得点差」の1ペアに限られている。(6) 小4と中2の共通37か国・地域でのペア比較（対応のある設計）は、国の構成の違いを統制できる有用な設計であるが、相関の学年間比較には用いられていない。(7) 小4「好き」と「自信」の $r=.45$ と中2の $r=.09$ を比較しているが、相関係数の差の検定（独立でない相関／異なるK）が行われていない。「連動しなかった」という表現が $r=.09$ の点推定のみ に 依拠し、CIが示されていない点も不備である。
論理の一貫性・構成	B	RQ1・RQ2に対応した結果提示と、生態学的誤謬（Robinson, 1950）、回答様式（Chen et al., 1995）、参照集団効果（Marsh & Hau, 2003）による説明仮説の提示は一貫している。仮説を「検証できない」と明示する姿勢も評価できる。一方で、(a) 理論枠組みのうち期待価値理論は触れられるが、Bandura の自己効力感理論と Pekrun の統制-価値理論（達成感情）は本文で実質的に利用されておらず、依拠すべき理論枠組みとしての深度が不足している。(b) 「期待価値理論と矛盾するとは言えない」という記述は、理論が個人内過程を述べるものである以上自明で、反証可能性のある予測が提示されていない。(c) 考察冒頭の「（国レベルで）好きが高いほど得点が低い」ことの説明において、「回答様式」が中2の「好き」と「価値」の連動を生むという推測と、「参照集団効果」が国間で得点の高い国の自信を低くするという推測が並列されているが、両者をデータで弁別する手立てが示されておらず、考察が仮説の羅列にとどまる。(d) 抄録で「国内の集団ごとの比較にもとづく解釈の可能性」とあるが、国内層間差のデータは収録指標に含まれる一方、国別の層間得点差と国平均得点の関連はほとんど報告されておらず、記述と提示の対応が弱い。
表現・体裁・引用規範	B	全体に誇張を避けた抑制的な表現で、国レベルの関連が個人の因果を示さないという注意が一貫して繰り返されている点は好ましい。ただし、参考文献が9本と少なく、Pekrun、Bandura、PISAによる国際比較文献（OECD報告書、Van de gaer et al., Nagengast & Marsh 等の「Big-Fish-Little-Pond」関連）、TIMSS 2023の公式技術報告書・質問紙尺度の定義（「とても好き」の尺度構成やカットオフ）への言及が不足している。Table/Figure の記述が本文から読み取れず（散布図や国別一覧の提示の有無が不明）、視覚的な外れ値・クラスターの確認ができない。「小4で5位、中2で4位」等の順位は標準誤差を考慮した統計的有意差の有無に触れておらず、順位の頑健性が不明である。

2. 総合講評 (Overall Critique)

本稿は、TIMSS 2023の国・地域別公表値(K=64)を学年別に分析し、「とても好き」「価値」の割合と平均得点の負の関連、「自信」割合と得点の無関連を報告するショートレターである。収録指標と本文の主張は整合しており、比率擬似相関や存在しない指標の分析といった致命的欠陥は認められない。生態学的誤謬の限界を明示し、因果解釈を避けている点も評価できる。しかし、(1)交絡(SIS・教育制度・経済水準・地域クラスター)が未統制のまま説明仮説(回答様式・参照集団効果)が並列されるのみで、データによる弁別がなく、(2)等ウェイト・標準誤差無視・相関差の検定欠如など統計処理が粗く、(3)Bandura・Pekrunの理論枠組みが実質的に使われず新規性も先行研究の更新に近い。これらは改稿で対応可能であり、大幅改稿を前提とした条件付採録(Major Revision)と判定する。

3. 主要修正要求事項 (Major Revisions : 採録に向けた必須対応事項)

以下の各項目は、学術論文としての信頼性および科学的妥当性を担保するために不可欠な修正要求です。再提出時には、修正箇所および各指摘への対応理由を明記した「修正対照表 (Rebuttal Letter)」を必ず添付してください。

[要求 1] 交絡要因の統制：国・地域レベルの共変量（1人当たりGDP、HDI、地域クラスター、授業時間・試験制度等）を用いた偏相関または重回帰（または少なくとも層別・クラスター頑健SEの感度分析）を追加し、「好き」と得点の負の関連が経済水準・地域構成で説明される程度を示すこと。可能であれば、共通37か国・地域に限定した学年間比較（対応のある設計）を行い、国構成の違いによるアーティファクトを検討すること。

[要求 2] 統計処理の精緻化：(a) 公表値の標準誤差や標本規模を考慮した重み付け分析・測定誤差を考慮した頑健性確認、(b) 小4と中2の相関差（例：「好き」×「自信」 $r=.45$ 対 $r=.09$ ）についてCIおよび差の検定を示すこと、(c) 報告した相関全体に対する多重性への対処方針、(d) 散布図と国別ラベルによる外れ値・クラスター（中央アジア・中東等）の可視化と、それらを除外した場合の頑健性を示すこと。

[要求 3] 説明仮説の弁別と理論枠組みの深化：回答様式の違い（極端回答傾向）と参照集団効果（BFLPE）の説明を並列するだけでなく、データで可能な範囲（例：「好きでない」割合や「とても好き」と「やや好き」の合計での関連、層間得点差の国別比較）で弁別を試みる。また、Bandura の自己効力感理論（個人内の予測と集合水準の差）と Pekrun の統制-価値理論（達成感情）を実質的に議論へ組み込み、期待価値理論の予測（個人内）と国間関連の乖離を理論的に整理すること。日本への教育的含意（自信を育てる手立て）は、本分析の範囲を超えるため、根拠を示すか削除すること。

4. 軽微な修正事項 (Minor Revisions : 表現・体裁等の改善点)

- TIMSSの質問紙尺度の定義（「とても好き」「とても自信あり」「とても価値あり」の構成とカットオフ、国間の測定不変性に関する技術報告書の知見）を明記し、参考文献を拡充すること（OECD/PISAによる類似の国際比較研究、Pekrun、Banduraの原典等）。平均得点の順位（日本が小4で5位、中2で4位）には標準誤差を考慮した有意差の有無を併記すること。
- $r=.09$ （中2「好き」×「自信」）等、「連動しなかった」と述べる箇所にはCIとBFを併記し、「証拠不十分」と「無関連の支持」を区別して表現すること。また、BF10の事前分布の設定（JJSの尺度パラメータ）と、BF10が3を超えれば「支持する証拠」とする基準の出典を示すこと。

5. 著者への試問・照会事項 (Questions to Authors)

- 「好き」の割合と得点の負の関連は、1人当たりGDPや地域クラスター（中央アジア・中東・北アフリカ等）を統制しても残りますか。残らない場合、本稿の主要な知見は経済水準や調査参加国の構成の産物ではないでしょうか。
- 「好き」と「価値」の $r=.93$ を「共通の要因（回答様式）」の反映とする推測は、「好きでない」「価値を感じない」（否定側）の割合の国間関連や、「やや好き」を含めた肯定側合計で検証できるのではないのでしょうか。また、国別の層間得点差（自信あり層と自信なし層の差）が国平均得点とどう関連するかをRQ2の一部として分析しなかった理由は何ですか。

6. 研究倫理および生成AI利用開示に関する審査所見

提示された原稿情報には、生成AIの利用範囲（データ収集・計算・文章作成・文献選定など）を明示した付記の記載が確認できず、カテゴリが「生成AI論文」であるにもかかわらず、開示の透明性を評価する材料が不足している。AIを用いた場合は、利用した工具・版、分析コード・出力の人手による検証、引用文献の実在確認（9本の参考文献の書誌情報の照合を含む）、および責任の所在を付記に具体的に記載するよう求める。特に、数値（相関、BF、国別値）の再現可能性を担保するため、国別データと分析スクリプトの公開を推奨する。

7. 本査読報告書の作成に関する開示（生成AIによる査読シミュレーション）

【付記：査読レポートの自動生成に関する透明性開示】

本査読報告書は、学術論文執筆を学ぶ学生や若手研究者への教育支援（批判的推敲プロセスの模擬体験）を目的として、大規模言語モデル・生成AI（Anthropic Claude / Google Gemini）を活用して自動生成された模擬査読レポートです。教育統計学・教育工学の厳格な学術基準（マクロ集計データの制約，生態学的誤謬の回避，交絡因子の統制，論理的整合性等）に準拠した指摘を行っていますが，実際の論文修正や教育現場への適用にあたっては，指導教員等の専門的助言とともに批判的に吟味してください。

【査読担当委員 審査所見結び】

本論文は公的オープンデータを適切にハンドリングし，教育工学的示唆を導出しようとする真摯な試みとして高く評価できます。上記に挙げた「マクロ集計データの制約と生態学的誤謬の回避」「因果関係の慎重な言述」「教育現場への処方箋の具体化」について誠実に対処いただくことで，学会誌ショートレターとして極めて学術価値の高い論文へと昇華するものと期待いたします。