

査読結果通知書・査読報告書（Peer Review Report）

審査対象論文	日本の子どもは算数・数学が好きなのか：TIMSS 2023で小4・中2を国際比較する
論文審査区分	生成AI論文（学術査読論文 / 刷り4頁以内）
査読判定結果	【条件付採録（Minor Revision）】
査読実施方式	生成AI（LLM / 模擬査読シミュレータ）による自動審査（学生教育・推敲支援）

1. 審査評価マトリクス（Evaluation Matrix）

審査評価項目	評価	評価所見および審査基準
独創性・新規性	B	日本の子どもは得点が高いのに算数・数学を好まないという話題は、TIMSS の報告書や先行研究で広く知られている。本稿の新しさは、2023年の公表値で日本の順位を更新したことと、国・地域間の「好き」と「自信」の関連を小4で調べたことにとどまる。一方で、国の間では「好き」と平均得点が負、国の中では正という向きの違いを同じ表から示した点は、短報として工夫がある。
有用性・教育的貢献	B	日本の位置（小4の「とても好き」22%で56番目、「とても自信あり」14%で最下位）を、平均得点の順位と並べて示しており、校内で子どもの意識を話し合うきっかけとして使いやすい。生態学的誤謬の例を学ぶ教材としても有用である。ただし授業への示唆は「話し合う材料にできる」にとどまり、効果は確かめていないと自ら書いているため、貢献は記述が中心である。
信頼性・統計的妥当性	B	本文の数値は事実ファイルと元データで確認でき、誤りはなかった（ $r=.45$ 、日本を除いて $r=.43$ 、1か国ずつ除いた範囲 $.41\sim.50$ 、中2の $r=.09$ など自分で再計算して一致した）。限界の記述も具体的である。ただし次の点が残る。(1)「とても好き」「とても自信あり」は、回答そのものではなく尺度の上位区分の割合で、中間層が見えない。(2)中2の $BF_{10}=0.14$ は「関連がない」と読めるが、95%CI は $[-.22, .38]$ で中程度の正の関連を除けない。(3)中2との比較は43か国の別集合である。
論理の一貫性・構成	B	RQ1・RQ2 と結果、考察の対応は明快で、因果の断定を避ける姿勢も一貫している。国の間と国の中で向きが逆になる点を、生態学的誤謬と回答の仕方の違いの両面から論じた構成は良い。弱い点は、その逆向きの説明に挙げた回答の仕方と比較の対象が、データでは検討されていない仮説であるにもかかわらず、考察の分量の大半を占めていること、および中2に関連が見られなかった理由を、国の集合の違いと切り分けていないことである。
表現・体裁・引用規範	B	文章は平易で、統計量の書き方も統一され、限界が項目立てで示されている。引用は主題に沿った実在の文献が中心である。ただし Marsh and Hau (2003) の比較の対象による自己概念の議論は主に学校内の比較についてのもので、国ごとの「とても」の基準の違いを支える引用としては距離がある。また、方法の「元データから再計算した p は、136組のボンフェローニ基準をわずかに下回った」は、基準を満たしたのか満たさなかったのかを読み取りにくい。

2. 総合講評（Overall Critique）

本稿は、TIMSS 2023 の公表値（小4が58、中2が43の国・地域）を使い、算数・数学を「とても好き」「とても自信がある」と答えた児童生徒の割合における日本の位置を整理し、小4で両者の国・地域間の関連を検討した短報である。本文の数値は、事実ファイルと元データに当たって確認し、誤りはなかった。私の再計算でも $r=.455$ (95%CI $[-.22, .64]$)、日本を除いた $r=.43$ 、1か国ずつ除いた r の範囲 $.41\sim.50$ 、日本の順位や平均値が一致した。姿勢も誠実で、集計値であること、生態学的誤謬、自己申告と回答の仕方、標本調査、交絡、多重比較を自ら述べ、国の間（ $r=-.65$ ）と国の中（「好き」群が9～57点高い）で向きが逆になる点を仮説にとどめている。これは評価できる。それでも次の点を直す必要がある。第1に、RQ2 のボンフェローニに関する文が、基準を満たしたのか分かりにくい。第2に、中2の「関連なし」の結論は、信頼区間が中程度の関連を除けないため強すぎる。第3に、学年差を「言い切れない」と退けたが、小4と中2の両方がある37か国に絞れば集合の違いを取り除け、確認できる。第4に、上位区分の割合は回答の偏りに左右されやすく、その限界を本文の中心に置くべきである。数値に誤りがなく、主張も慎重なため、Minor Revision とする。

3. 主要修正要求事項（Major Revisions：採録に向けた必須対応事項）

以下の各項目は、学術論文としての信頼性および科学的妥当性を担保するために不可欠な修正要求です。再提出時には、修正箇所および各指摘への対応理由を明記した「修正対照表（Rebuttal Letter）」を必ず添付してください。

〔要求 1〕多重比較の文を言い換えること。結果の「元データから再計算した p は、136組のボンフェローニ基準をわずかに下回った」は、 p が基準より小さい（基準を満たした）のか、基準に届かなかったのかを読み取れない。私の再計算では $p=.00033$ 、基準は $.05 \div 136=.00037$ で、わずかに基準を満たすが、補正後の p は約 $.045$ と境界に近い。「基準をわずかに満たした」と書き、補正後の p の値（約 $.045$ ）を添え、136組には RQ と無関係な組や計算でつながった組が多く、基準が厳しめであることも一言述べること。

〔要求 2〕中2の「関連なし」の書き方を弱めること。補足の「BF10 は関連がないことを支持した（ $r=.09$, 95%CI $[-.22, .38]$, BF10=0.14）」は、信頼区間が $r=.38$ までを含むため、中程度の正の関連を除けない。「小4のような関連は見られなかった」にとどめ、JZS の事前分布に依存する証拠であることを注記すること。

〔要求 3〕学年差の扱いを確かめること。考察は「対象の国・地域も異なるため、学年による違いとは言い切れない」で終わっているが、両学年がそろそろ37か国に絞って同じ相関を出せば、集合の違いを取り除ける。私の再計算では、その37か国で、「好き」と「自信」の r は小4で $.43$ 、中2で $.26$ であり、中2の方が弱い、 $.09$ ほど小さくはなかった。この結果を1行で示し、中2の43か国での $r=.09$ と比べて、集合の違いが影響したことを明記すること。

〔要求 4〕上位区分の割合を使う限界を前に出すこと。「とても好き」「とても自信あり」は尺度の上位区分の割合で、日本のような中間の選択肢を選ぶ傾向のある国では低く出うる。「と答えた」と書いているが、カタログの説明では尺度の区分であり、個々の質問への回答そのものではない可能性がある。このため、表現を「尺度の上位区分に入る」に改めるか、確認のうえ区分の定義を方法に書くこと。あわせて、3区分のうち「中間」の割合も表にして、日本の「とても」の低さが「好きでない」の高さによるのか、「やや好き」に集まっているのかを分けて示すこと。

〔要求 5〕回答の仕方の説明の位置づけを調整すること。考察は、Chen et al. (1995) と Marsh and Hau (2003) を挙げて、国ごとに異なる基準で自己評価している可能性を述べている。仮説と明記してはいるが、Marsh and Hau は主に学校内の比較についての議論であり、国の間の基準の違いを直接支えない。文献が何を示したかを正確に書き、国の間の差を説明する候補として、ほかの要因（教育課程の違い、質問文の翻訳、経済水準）と並べること。

4. 軽微な修正事項（Minor Revisions：表現・体裁等の改善点）

- ・「小4の「とても好き」22%（単純平均44.34%）で56番目」は、22%が3か国（台湾、日本、韓国）の同値であることが本文に書かれているが、アブストラクトでは読み取れない。アブストラクトにも「同率」と添えること。
- ・「日本の平均得点は小4が591点（5番目）、中2が595点（4番目）」は、順位の根拠となる上位の国・地域（シンガポール、台湾、韓国、香港）を一覧表にすると、読み手が確かめやすい。
- ・国の間で $r=.45$ と $\rho=.42$ が近いのに、「平均得点との負の相関」では $r=-.65$ と $\rho=-.75$ が大きく離れる。後者は曲線的な関連か外れ値の影響を示すため、散布図か一文の説明を足すこと。

5. 著者への試問・照会事項（Questions to Authors）

- ・小4と中2の両方がそろそろ37か国に絞ると、「好き」と「自信」の関連は小4で $r=.43$ 、中2で $r=.26$ であった（私の再計算）。この比較を本文に加えたとき、学年による違いについて、どこまで述べられるか。
- ・「とても」の割合ではなく、3区分の全体の分布（とても、やや、肯定しない）や尺度の平均で見たとき、日本の位置は変わるか。上位区分だけを使った理由は何か。
- ・国の間の負の相関（ $r=-.65$ ）と国の中の正の差（9～57点）の食い違いは、国の平均得点の高さと「とても」と答える基準の違いのどちらによると考えるか。TIMSS の個票を使えば、この2つを分けられるか。

6. 研究倫理および生成AI利用開示に関する審査所見

本文中に生成AIの利用に関する記述はないが、付記は自動で付く。本文の数値は元データで確認できたため、付記に、数値と引用を人手で照合した旨を加えるとよい。

7. 本査読報告書の作成に関する開示（生成AIによる査読シミュレーション）

【付記：査読レポートの自動生成に関する透明性開示】

本査読報告書は、学術論文執筆を学ぶ学生や若手研究者への教育支援（批判的推敲プロセスの模擬体験）を目的として、大規模言語モデル・生成AI（Anthropic Claude）を活用して自動生成された模擬査読レポートです。実際の論文修正や教育現場への適用にあたっては、指導教員等の専門的助言とともに批判的に吟味してください。

【査読担当委員 審査所見結び】

本論文は公的オープンデータを適切にハンドリングし、教育工学的示唆を導出しようとする真摯な試みとして高く評価できます。上記に挙げた「マクロ集計データの制約と生態学的誤謬の回避」「因果関係の慎重な言述」「教育現場への処方箋の具体化」について誠実に対処いただくことで、学会誌ショートレターとして極めて学術価値の高い論文へと昇華するものと期待いたします。