

査読結果通知書・査読報告書（Peer Review Report）

審査対象論文	数学の男女の得点差は、国によってどう違うのか：PISA 2025の90の国・地域を並べる
論文審査区分	生成AI論文（学術査読論文 / 刷り4頁以内）
査読判定結果	【条件付採録（Minor Revision）】
査読実施方式	生成AI（LLM / 模擬査読シミュレータ）による自動審査（学生教育・推敲支援）

1. 審査評価マトリクス（Evaluation Matrix）

審査評価項目	評価	評価所見および審査基準
独創性・新規性	C	OECDの公表表にある男女差の列を、標準誤差つきで並べ直したもので、新しい知見はない。標準誤差の1.96倍と.05÷90の2つの基準を併記し、1か国ずつ除く確認までつけた点は、記述研究の手順を学ぶ教材として価値がある。ただし先行研究（Else-Quest et al. 2010 など）が国による違いを扱っており、本研究が加える点は2025年の値という新しさにほぼ限られる。
有用性・教育的貢献	B	「差が大きい国」の順位表で終わらせず、日本の差の標準誤差が90の国・地域で2番目に大きく、順位が確かでないことを示した点は、順位表を読む練習として役に立つ。また「男子が高い71、女子が高い19」と「差があると言える62と44」を分けて書き、一方向の現象ではないと述べたのも適切である。一方、国・地域間の差の幅のうち、推定誤差で説明される部分がどれだけかが示されておらず、「国によって大きく異なる」という中心の主張が最後の一步まで届いていない。
信頼性・統計的妥当性	B	本文の数値は、事実ファイルと元データに当たり、2通りの方法で再計算して一致した（確認した数値は40余り、誤りは0件）。因果の断定、生態学的誤謬、交絡、多重比較、標本の限界も本文に書かれている。残る問題は計算ではなく解釈である。上位10を除く確認は日本自身を除くため、日本の位置の頑健性を支えない。日本の位置を「信頼区間が平均を含むか」で判断する方法も粗い。男女の在籍率の違いが差に与える影響も書かれていない。
論理の一貫性・構成	B	RQ1とRQ2は、方法、結果、考察で対応している。限界(1)～(6)も本文の分析内容と合っている。弱い点は2つある。第1に、方法の「全ペアの探索は1組のみ（ボンフェローニの基準は.05÷1）」は、結果として報告しない相関に補正の基準を書いており、読者が何の検定の話か分からない。第2に、上位10を除く確認の目的が方法に書かれておらず、結果の使い道も考察で誤っている。
表現・体裁・引用規範	B	文体は平易で、「男子のほうが高い」「言えない」の使い分けが一貫している。引用も、Hyde et al. (2008) の「類似性」は本研究では判断できない、Guiso et al. (2008) などは仮説にとどまる、と書き分けており、主張を超えて使われていない。直す点は、日本語の要旨に44（.05÷90の基準）が入っておらず、英文要旨とずれていること、考察の「71対19に近い偏り」が数字で示されていないことである。

2. 総合講評（Overall Critique）

数値の面では堅実な論文である。本文の40余りの数値（記述統計、71対19、62（男子55・女子7）、44（男子41・女子3）、日本の順位、95%信頼区間5.1～27.5点、標準誤差の順位、注意（*）の6か国を除く84での65・19・57・17番目、上位10を除く80での61・19・53、1か国ずつ除いた18か19と61か62）を元データから2通りで計算し直し、すべて一致した。因果を断定せず、生態学的誤謬、交絡、多重比較、標本の限界も書いており、論文が言っていないことを批判する余地は少ない。一方、主張と根拠の対応に4点の弱さがある。(1) 上位10を除く分析は日本自身を含むため、考察の「日本が大きい側にあることは変わらなかった」を支えない。(2) 「国によって大きく異なる」には、標準誤差を考慮した異質性の検定がない。私の計算では $Q=1046$ （自由度89）、 $I^2=91\%$ で、差の幅は推定誤差だけでは説明できない。(3) 日本の位置を「信頼区間が平均差を含むか」で判断するのは、比較の方法として粗い。(4) 学校に在籍する15歳に限られることが、男女の在籍率が違う国で差を偏らせうる点と、国でない単位を同じ重みで扱う点が十分に扱われていない。いずれも文章と補助分析で直せるため、Minor Revisionとする。

3. 主要修正要求事項（Major Revisions：採録に向けた必須対応事項）

以下の各項目は、学術論文としての信頼性および科学的妥当性を担保するために不可欠な修正要求です。再提出時には、修正箇所および各指摘への対応理由を明記した「修正対照表（Rebuttal Letter）」を必ず添付してください。

[要求 1] 考察第1段落の「注意（*）のある国や上位の国を除いても、71対19に近い偏りと、日本が大きい側にあることは変わらなかった」を直すこと。平均得点の上位10には日本（5番目）が入っており、「上位10を除く80」では日本が分析から消える。結果もこの分析では日本の順位を書いていない。したがって日本の位置の頑健性は、注意（*）の6か国を除く場合（17番目）と、1か国ずつ除く場合（18か19番目）に限られる。上位10を除く分析は、差の全体の偏り（80で男子61・女子19、基準を超えるのが53）の確認にとどめ、日本には言及しないこと。そもそもこの分析を何のために行うのかを方法に一文書くこと（得点の高い国が差を決めているかを見るなら、男女計の得点と差の関係を使う必要があり、報告しない相関と同じ問題に戻る）。

[要求 2] 「国によって大きく異なる」を支える異質性の検定を加えること。差の標準偏差9.33点には、各国の推定誤差による散らばりが含まれる。私は逆分散の重みでCochranのQを計算し、 $Q=1046$ （自由度89）、 $I^2=91\%$ を得た（プレーンなPythonとNumPyの2通りで一致、ザンビアを除いても同じ）。ランダム効果モデルの国間の標準偏差は約8.3点、平均は7.9点（単純平均は8.04点、逆分散の重み付き平均は7.58点）である。差の分散87.0に対し、標準誤差の2乗の平均は11.5にすぎないので、結論は変わらない。ただ、検定を示すと「差は国によって違う」が推定誤差ではなく実質的な違いであると言い切れる。

[要求 3] 日本の位置の判断方法を直すこと。結果は「95%信頼区間が平均差8.04点を含むので、平均より大きいとは言い切れない」と書く。しかし平均差自体にも不確かさがあり、信頼区間が値を含むことは、2つの値の差の検定とは同じではない。 $(16.3-8.04) \div 5.7=1.45$ （2通りの計算で一致、 $p=.15$ ）をそのまま書くのが適切で、結論は変わらない。また「大きい側から19番目」の順位にも標準誤差による幅がある。標準誤差から差を乱数で再現して順位の90%区間を示す手順は、本研究が教える「順位は確かでない」を数字で見せる最も強い材料になる。平均得点の順位（日本5番目）にも、韓国（522.3点）や香港（521.7点）が近いので、同様の注意を一文加えること。

[要求 4] 標本の限界を、差の読み方に結びつけて書くこと。限界(2)は「学校に在籍する15歳に限られる」と書くが、男女で在籍率が違う国では、在籍者の男女の構成が偏り、得点の差そのものが選抜の影響を受ける。差の上位に低所得国のルワンダ（23.0点）、ザンビア、ケニアが入っているので、この点は無視できない。OECDの表にある在籍の割合（被覆率）を使うか、使えない場合は「差の大きさは各国の15歳全体の差ではない」と明記すること。また90の単位には、ドゥシャンベ、ウクライナの17地域、北京・上海・江蘇・浙江、クルディスタン、香港、マカオが含まれる。題名と要旨の「国によって」は「国・地域によって」とし、単位が国でないものを同じ重みで数えていることを方法に書くこと。

[要求 5] 多重比較の説明を整理すること。方法の「全ペアの探索は…1組のみ（ボンフェローニの基準は $.05 \div 1$ ）」は、結果に載せない相関についての記述で、読者には補正の話に見えない。「数学得点（男女計）と差の相関は、男女計が男子と女子の得点から作られ計算でつながるので報告しない」の一文に直すこと。また考察の「RQ2の62は5%水準を90回繰り返した結果」は、62の大半が偽陽性かのように読める。90回の検定で名目5%の偽陽性は期待値で4.5件であり、62はそれを大きく上回る。補正後の数は、Bonferroni（ $.05 \div 90$ ）とHolmで44（2通りで一致）、偽発見率5%のBenjamini-Hochbergでは60である。基準によって44から62の幅があることを、考察に書くこと。

4. 軽微な修正事項（Minor Revisions：表現・体裁等の改善点）

- 日本語の要旨に、補正後の数（ $.05 \div 90$ の基準で44）を入れること。英文要旨には44が入っているが、日本語の要旨は62までしか書かれておらず、読者が受け取る結論が言語によって違う。
- 考察の「71対19に近い偏り」は、除いた場合の実際の数字（注意（*）の6か国を除く84で65対19、上位10を除く80で61対19）を書くこと。「近い」では、読者が確かめられない。
- 日本の平均得点の順位（5番目）にも、差の順位と同じ不確かさの注意を添えること。日本は525.4点で、次の韓国は522.3点、香港は521.7点であり、平均得点の標準誤差は本文の事実ファイルにないが、順位が入れ替わらないとは限らない。「5番目」は「公表値の順では5番目」と書くのが正確である。

5. 著者への試問・照会事項（Questions to Authors）

- 上位10を除く分析の目的は何か。日本が入っている集団を除く分析から、日本の位置について何を示したかったのか。得点の水準と差の関係を見たかったのなら、報告しなかった相関（ $r=.31$ ）をなぜ載せないのか。
- 差の国間の違いのうち、推定誤差で説明される割合を、どう見積もるか。Q統計量や I^2 を使わずに、「国によって大きく異なる」と書いた根拠を知りたい。
- 低所得国の差（ルワンダ、ザンビア、ケニア）は、在籍する生徒の選抜の影響を受けていると考えないか。被覆率の低い国・地域を除いたとき、71対19と62という結論はどの程度変わると見込むか。

6. 研究倫理および生成AI利用開示に関する審査所見

付記はPDFの末尾に自動で付くため、本文にないことは評価しない。本文は事実と仮説を分け、因果の断定を避けている。人がどこまで数値を確かめたかが付記に書かれていることが望ましい。

7. 本査読報告書の作成に関する開示（生成AIによる査読シミュレーション）

【付記：査読レポートの自動生成に関する透明性開示】
本査読報告書は、学術論文執筆を学ぶ学生や若手研究者への教育支援（批判的推敲プロセスの模擬体験）を目的として、大規模言語モデル・生成AI（Anthropic Claude）を活用して自動生成された模擬査読レポートです。実際の論文修正や教育現場への適用にあたっては、指導教員等の専門的助言とともに批判的に吟味してください。

【査読担当委員 審査所見結び】
本論文は公的オープンデータを適切にハンドリングし、教育工学的示唆を導出しようとする真摯な試みとして高く評価できます。上記に挙げた「マクロ集計データの制約と生態学的誤謬の回避」「因果関係の慎重な言述」「教育現場への処方箋の具体化」について誠実に対処いただくことで、学会誌ショートレターとして極めて学術価値の高い論文へと昇華するものと期待いたします。