

査読結果通知書・査読報告書（Peer Review Report）

審査対象論文	好き・自信・価値を同時に見ると、得点との関連はどう変わるか：TIMSS 2023の中2を重回帰とパス解析で整理する
論文審査区分	生成AI論文（学術査読論文 / 刷り4頁以内）
査読判定結果	【条件付採録（Minor Revision）】
査読実施方式	生成AI（LLM / 模擬査読シミュレータ）による自動審査（学生教育・推敲支援）

1. 審査評価マトリクス（Evaluation Matrix）

審査評価項目	評価	評価所見および審査基準
独創性・新規性	B	「好き」「自信」「価値」を同時に重回帰へ入れ、共線性（VIF 7.3と7.4）で係数が不安定になる様子と、国どうしと国内で関連の向きが逆になることを同じ表の中で見せる構成には教材としての価値がある。一方、手法は標準的で、先行研究（Shen and Tam 2008 など）が示した逆説的な関係を43の国・地域で再確認した範囲にとどまる。パス解析とSEMは、新しい知見ではなく手法の学習材料である。
有用性・教育的貢献	A	前回指摘した国内の層の差（「好き」+49.5点、「価値」+39.8点、「自信」+109.1点、正の国は42, 42, 43か国）が結果と授業づくりの欄に入り、「国どうしは負でも国内は正」という生態学的誤謬の核心が具体的な数字で読めるようになった。背景の未調整と標準誤差がないことも添えられている。教育現場への効果は「確かめられていない」と明記しており、過剰な示唆もない。
信頼性・統計的妥当性	B	本文の数値は、自前の再計算（相関, 95%CI, ρ , 重回帰, VIF, HC3, 1か国除外, 上位5除外, 国内差, ウィリアムズの検定, クックの距離, パス解析, SEM）と一致した。パス解析の $\chi^2=1.884$ （自由度2）も2通りで再現できた。残る問題は、数値ではなく説明の2点である。第1に、同じ質問の別区分を「合計が約100%」と書いているが、実際は約68%で、残りは「やや好き」である。第2に、SEMの不適合を「設定が主因」と読むが、誤差相関を加えても適合は悪いままである。
論理の一貫性・構成	B	RQ1・RQ2と方法、結果、考察の対応は明確で、前回の「上位国に左右される」は「共線性による配分の変化かもしれない」へ、パス解析の順序の根拠のなさも考察に書き直された。残る弱い点は、パス解析の適合を「直接パスを置く仮定も検定しておらず」と書く点である。自由度2の χ^2 は、省いた2本のパスの検定を兼ねており、ただ検出力が低いので「検定できていない」のではなく「ほとんど検出できない」と書くのが正確である。
表現・体裁・引用規範	B	文体は平易で、r, CI, p, BF10, VIF, ウィリアムズの検定の記載が揃っている。引用は、Marsh and Hau (2003) を国内の学校間の比較で「類推にとどまる」と書き直したことで主張を支えている。残る点は、BF10の「事前分布の尺度は既定値」では再現できないこと、英文要旨に complementary response categories とあることである。後者は上の「合計が約100%」と同じ誤りを引き継ぐ。

2. 総合講評（Overall Critique）

第2版は、前回の指摘（major 5件, minor 3件）にほぼ応えている。(1) 上位5除外の解釈は、2つの β の合計が -0.77 と -0.76 でほぼ同じ、単独の r も -0.74 のままという事実を根拠に「共線性による配分の変化かもしれない」へ改まり、解消した。(2) 「自信」は「関連が確認できなかった」へ弱まり、頑健な標準誤差の $p=0.089$ と抑制の説明も入って、ほぼ解消した。(3) パス解析は、 χ^2 が1.884（自由度2）に直り、間接効果の解釈の限界も書かれ、ほぼ解消した。(4) SEMは構造係数を参考にとどめたが、不適合の原因の読みに新しい行き過ぎが残り、一部解消にとどまる。(5) 国内の層の差は加わり、解消した。minorのウィリアムズの検定（ $t=-1.60$, $p=0.118$ ）、クックの距離、Marsh and Hauの類推も直った。新しく入った主張を元データから2通りで計算し直したところ、数値の誤りは見つからなかった。ただし、言葉の誤りが2つある。「好き」と「好きでない」の合計は約100%ではなく平均67.6%であること、SEMの不適合を設定が主因と読む点が強すぎることである。さらに、上位5を除くと「自信」の単独の r が0.40（ $p=0.012$ ）になる事実は、「不安定」の中身として書く価値がある。いずれも文章の修正で足りるため、Minor Revisionとする。

3. 主要修正要求事項（Major Revisions：採録に向けた必須対応事項）

以下の各項目は、学術論文としての信頼性および科学的妥当性を担保するために不可欠な修正要求です。再提出時には、修正箇所および各指摘への対応理由を明記した「修正対照表（Rebuttal Letter）」を必ず添付してください。

[要求 1] 「合計が約100%」を直すこと。考察の第3段落は、「好き」と「好きでない」、「価値」と「価値を感じない」を「同じ質問の別区分（合計が約100%）」と書く。しかし質問は3区分（とても、やや、肯定しない）で、中2の「とても好き」と「好きでない」の合計は国平均で67.6%（日本は10+59=69%）であり、約100%ではない。残りの約32%は「やや好き」にあたる。これは補数ではなく、同じ質問の2つの区分である。方法・考察・英文要旨の「補数」「complementary」も、「同じ質問の2つの区分」に改めること。相関が-.95と高いのは、区分が同じ回答分布の両端であるためで、計算上の恒等式ではない。

[要求 2] SEMの不適合の読みを弱めること。考察は、不適合の主因を「誤差の相関なしで入れた設定」とみて「実質的な知見ではない」と書く。私は「好き」と「好きでない」、「価値」と「価値を感じない」に誤差相関を足した同じモデルを2通りの最適化（Nelder-Mead と、複数の初期値からのPowell）で当てはめた。 χ^2 は62.87（自由度8）から32.23（自由度6）へ下がったが、 $p<.001$, CFI=.955, RMSEA=.319で、適合は悪いままだった。設定は不適合の約半分を説明するにとどまる。「主因」は「一因」に、「実質的な知見ではない」は「何が原因かはこの設定では切り分けられない」に直すこと。1つの潜在変数で4指標をまとめること自体が合わない可能性も残る。

[要求 3] パス解析の適合の書き方を正確にすること。考察は「直接パスを置かない仮定も検定しておらず」と書くが、自由度2の χ^2 は、省いた2本のパス（好き→得点、自信→価値）を同時に0とおく検定である。私はそれぞれを足して分解した。好き→得点だけで χ^2 の増分は0.43（ $p=.51$ ）、自信→価値で1.45（ $p=.23$ ）、合計は1.88で本文の χ^2 と一致した（回帰の $\beta=.172$, 95%CI [-.45, .81]とも整合する）。ただし「好き」と「価値」の相関が.93で検出力がほとんどなく、「検定で否定されなかった」ことは「直接の関連がない」証拠にならない。「検定しておらず」は「自由度2の検定は検出力が低く、直接パスの有無を判断できない」に直すこと。要旨の「パス解析の適合は良かった」にも、適合は順序や因果の証拠でないことを一言添えるといい。

[要求 4] 「自信」の不安定さを具体的に書くこと。結果は、重回帰で「自信」の $\beta=.245$ 、上位5除外で $\beta=.409$ （ $p<.001$ ）と書き、単独の $r=.12$ は「確認できなかった」とする。私が上位5か国を除いて単独の r を計算すると、 $r=.40$ （ $p=.012$ ）になる（2通りの計算で一致）。つまり「自信」の関連は、得点の最も高い5か国（「自信」が低い）を含めると消え、除くと現れる。これは抑制の説明だけでは足りず、一部の国・地域が関連を打ち消す構造である。上位5除外の項に「自信」の単独の $r=.40$ を一文加え、要旨の「関連は確認できなかった」を「全体では確認できなかったが、上位5を除くと正の関連が現れる」と書くこと。

4. 軽微な修正事項（Minor Revisions：表現・体裁等の改善点）

- BF10の事前分布を明記すること。方法は「事前分布の尺度は既定値」とだけ書くが、0.16は、Wetzels and Wagenmakers (2012) のJZS（尺度1, pingouin等の既定値）の値である（私の再計算でも0.160）。一樣な事前分布（Jeffreys, Lyらの $kappa=1$ ）では0.25, $kappa=0.5$ では0.37（基準1/3を超える）であった。使ったソフトウェアと尺度を書き、「関連が確認できなかった」を支える範囲で結論を弱くしておくこと。
- 限界(8)の「クックの距離がコートジボワール0.42、日本0.28と基準（0.093）を超える」は、基準を超えるのが5か国（ほかに南アフリカ0.20、ウズベキスタン0.15、シンガポール0.099）であることを書くことと正確になる。また上位5除外は、結果変数（得点）の高い側を切る操作で、得点の範囲を狭めて β や相関を変える。この点を限界に一文加えること。ブートストラップ区間は、事実ファイルの値（「自信」の上限.49、「価値」の下限-1.61）と私の2万回の再計算（.45, -1.54）で端がやや異なる。乱数の違いの範囲だが、反復回数と乱数の種を方法に書くことと追試できる。
- 結果の「日本の「とても好き」は10%で、同じ値の国が5か国」は、日本を含めた数（日本を含め5か国）か、ほかに5か国かが読み取れない。「日本を含め5か国」と書くこと。

5. 著者への試問・照会事項（Questions to Authors）

- パス解析の自由度2は、省いた「好き→得点」と「自信→価値」の2本のパスの検定にあたる。この2本のうち、どちらが理論上より重要か、また「自信→価値」を足したモデルでも結論は変わらないかを教えてほしい。
- SEMに誤差相関を足しても適合が悪い（私の計算で $\chi^2=32.2$ 、自由度6, CFI=.955, RMSEA=.319）なら、1因子でまとめる構造自体が合わないとは考えられないか。「主因は設定」と判断した根拠を知りたい。
- 上位5除外は「得点の高い側」を切る操作で、結果変数による選択になる。「自信」の単独の r が-.12から.40へ変わることを、国のグループ（東アジア）の効果とみるか、範囲の制限による見かけとみるか。論文の立場を教えてほしい。

6. 研究倫理および生成AI利用開示に関する審査所見

生成AIの付記はPDFの末尾に自動で付くため、本文にないことは評価しない。本文は事実と仮説を分けて書き、数値も事実ファイルと一致した。言葉の誤りが2点残るので、付記に人による確認の範囲が書かれていることが望ましい。

7. 本査読報告書の作成に関する開示（生成AIによる査読シミュレーション）

【付記：査読レポートの自動生成に関する透明性開示】

本査読報告書は、学術論文執筆を学ぶ学生や若手研究者への教育支援（批判的推敲プロセスの模擬体験）を目的として、大規模言語モデル・生成AI（Anthropic Claude）を活用して自動生成された模擬査読レポートです。実際の論文修正や教育現場への適用にあたっては、指導教員等の専門的助言とともに批判的に吟味してください。

【査読担当委員 審査所見結び】

本論文は公的オープンデータを適切にハンドリングし、教育工学的示唆を導出しようとする真摯な試みとして高く評価できます。上記に挙げた「マクロ集計データの制約と生態学的誤謬の回避」「因果関係の慎重な言述」「教育現場への処方箋の具体化」について誠実に対処いただくことで、学会誌ショートレターとして極めて学術価値の高い論文へと昇華するものと期待いたします。